## Министерство образования Российской Федерации

# МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ им. Н.Э. БАУМАНА

Факультет: Информатика и системы управления Кафедра: Информационная безопасность (ИУ8)

## Методы оптимизации

# Домашнее задание №2 на тему: «Исследование генетических алгоритмов в задачах поиска экстремумов»

Вариант 5

Преподаватель:

Коннова Н.С.

Студент:

Девяткин Е.Д.

Группа:

ИУ8-34

Репозиторий работы: <a href="https://github.com/ledibonibell/MO-hw02">https://github.com/ledibonibell/MO-hw02</a>

Москва 2023

## Цель работы

Изучить основные принципы действия генетических алгоритмов на примере решения задач оптимизации функций двух переменных.

#### Постановка задачи

Найти максимум функции f(x,y) в области D с помощью простого генетического алгоритма. За исходную популяцию принять 4 случайных точки. Хромосома каждой особи состоит из двух генов: значений координат x,y. В качестве потомков следует выбирать результат скрещивания лучшего решения со вторым и третьим в порядке убывания значений функции приспособленности с последующей случайной мутацией обоих генов. В качестве критерия остановки эволюционного процесса задаться номером конечной популяции N:  $(10^1 \dots 10^2)$ . Визуализировать результаты расчетов.

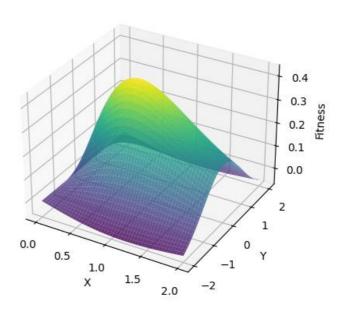
## Ход работы

Заданная функция:

$$f(x,y) = \frac{\sin(x)\sin(y)}{1 + x^2 + y^2}$$

Область:

$$D = (0,2) \times (-2,2)$$



**Рис. 1.** График функции f(x, y)

Сгенерированные числа, а также среднее и максимальное значения FIT— функции популяции для поколений  $N=1\dots 10$  представлены в сводной таблице 1.

№ поколения	X	Y	FIT	Максимальный результат	Средний результат
0	1.3958	1.0748	0.1142	0.3126	0.217
	1.4901	-0.5033	0.2514		
	1.8722	-0.3888	0.1898		
	1.3477	0.3451	0.3126		
	1.474	-0.4077	0.2737	0.3331	0.2742
1	1.3939	0.0696	0.3331		
	1.8433	-0.3483	0.2003		
	1.5636	0.0430	0.2899		
	1.3939	0.0696	0.3331	0.3331	0.3068
2	1.3939	0.0696	0.3331		
	1.7125	-0.2267	0.2421		
	1.4540	0.0138	0.3189		
3	1.3939	0.1561	0.3277	0.3331	0.3256
	1.3939	0.0696	0.3331		
	1.4520	0.0156	0.3194		
	1.4379	-0.0560	0.3223		
4	1.4059	0.0984	0.3287	0.3287	0.3262
	1.4316	-0.0256	0.3246		
	1.4287	0.072	0.3241		
	1.3979	0.1464	0.3275		
5	1.4089	0.0949	0.3282	0.3459	0.3328
	1.4234	0.0782	0.3252		
	1.3981	0.0686	0.3321		
	1.3239	0.1458	0.3459		

	1.4158	0.087	0.3268		
6	1.4205	0.0815	0.3258	0.3268	0.3252
	1.4371	0.0698	0.3220	0.3200	0.3232
	1.4200	0.0769	0.3261		
7	1.4217	0.0357	0.327	0.3270	0.3256
	1.4336	0.0727	0.3228		
	1.4165	0.0861	0.3266		
	1.4204	0.0816	0.3258		
8	1.4188	0.064	0.327	0.3270	0.3253
	1.421	0.0425	0.327		
	1.4328	0.0702	0.3231		
	1.4306	0.0633	0.3239		
9	1.4313	0.0655	0.3237	0.3237	0.3202
	1.4812	0.0645	0.3108		
	1.4325	0.0692	0.3232		
	1.4324	0.0689	0.3233		
10	1.4324	0.0689	0.3233	0.3233	0.3233
	1.4325	0.0691	0.3232		
	1.4323	0.0687	0.3233		
	1.4324	0.0688	0.3233		
	1	i.	L	I	l

### Таблица 1.

Также стоит понимать, что значения за 10 и 100 поколения отличаются, где последнее является более приближенным к действительности:

FIT(1.1913; 0.0549) = 0.3829

Overall Best Solution: (1.1913, 0.0549), Overall Best Fitness: 0.3829

Пример расположения точек на начальном поколении приведен на рис. 2, а также для десяти поколений на рис. 3-8.

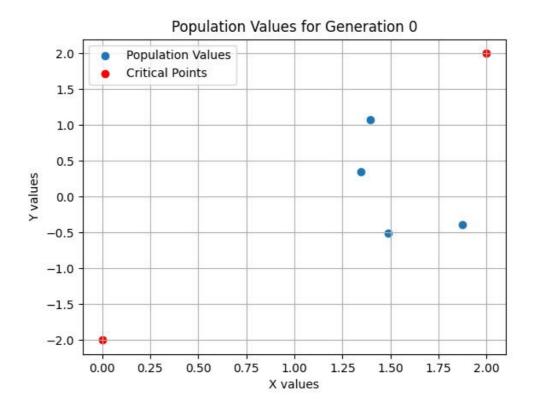


Рис. 2.

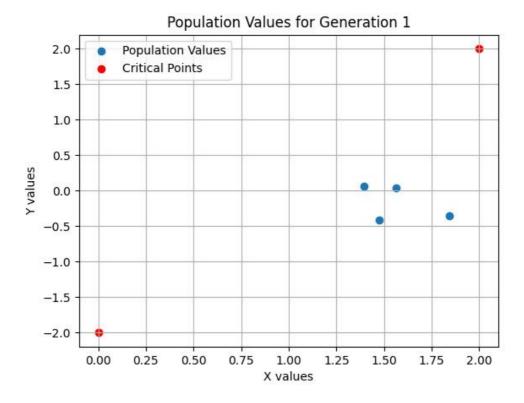


Рис. 3.

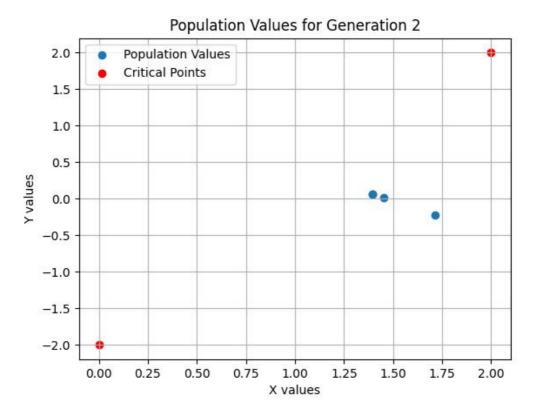


Рис. 4.

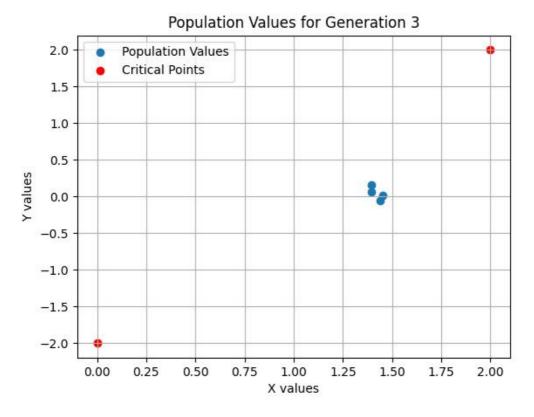


Рис. 5.

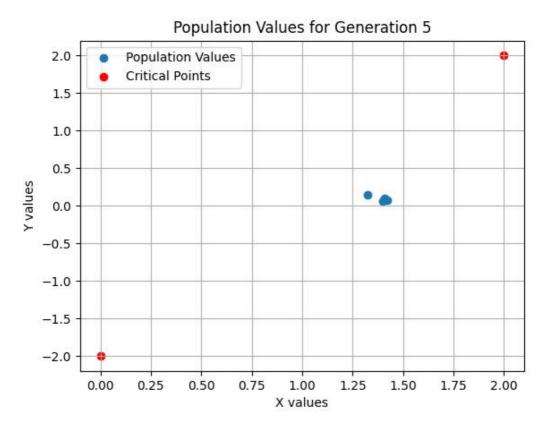


Рис. 6.

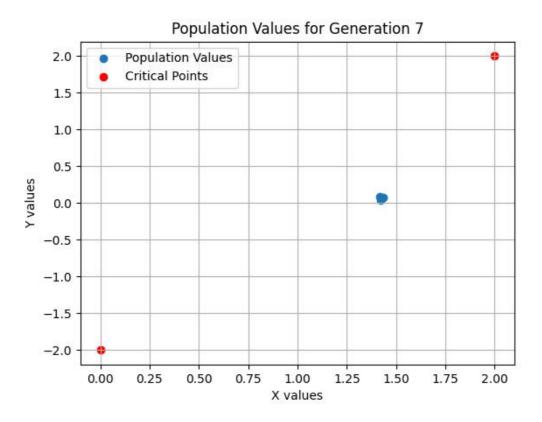
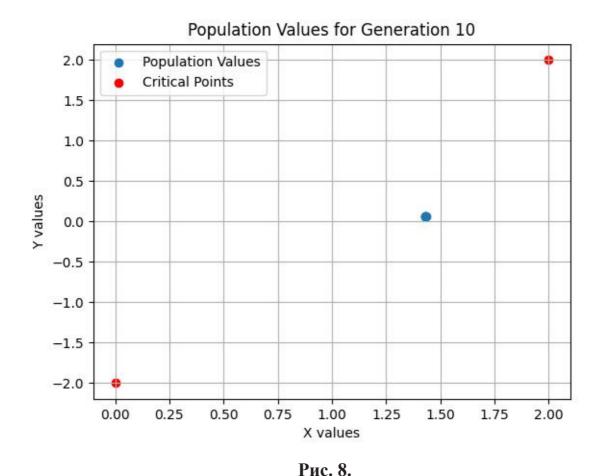


Рис. 7.



Как видно из таблицы 1, а также на рис. 6., уже к 6 - 7 поколениям происходит схождение алгоритма и хромосом всех особей в популяции, а результат вычисления приближен к искомому (но не достаточно близко!).

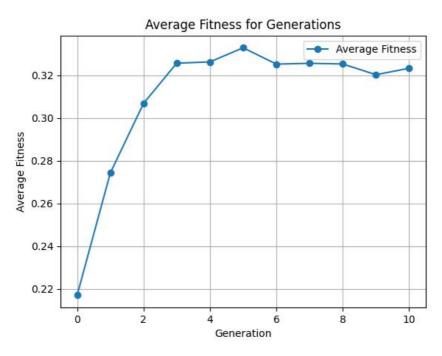


Рис. 9. График зависимости среднего значения FIT от номера популяции

# Вывод

В ходе выполнения работы был изучен генетический алгоритм на примере поиска оптимального решения. Было выявлено, что уже к 10 поколению мы приблизились к оптимальному решению (при 100 существующих), что обусловлено использованием элитарного механизма селекции особей для скрещивания.

Значения, полученные в ходе работы, оказались близки к действительности, что еще раз доказывает правильность выполнения алгоритма.

```
Приложение А
```

```
Файл 'Main.py':
import numpy as np
import matplotlib.pyplot as plt
L = 10
def fitness function(x, y):
  return np.sin(x) * np.cos(y) / (1 + x ** 2 + y ** 2)
definitialize population(population size):
  population = []
  for in range(population size):
     x binary = ".join(np.random.choice(['0', '1']) for in range(L))
     y binary = ".join(np.random.choice(['0', '1']) for in range(L))
     x = int(x binary, 2) / (2 ** L - 1)
     y = -2 + int(y binary, 2) / (2 ** L - 1) * 4
     population.append((x, y))
  return population
def roulette selection(population, fitness values):
  total fitness = sum(fitness values)
  probabilities = [max(0, fitness / total fitness)] for fitness in fitness values
  probabilities /= np.sum(probabilities)
  selected index = np.random.choice(len(population), p=probabilities)
  return population[selected index]
def two point crossover(parent1, parent2):
  point1 = np.random.randint(1, L)
  point2 = np.random.randint(point1, L)
  x binary parent1 = bin(int((parent1[0] * (2 ** L - 1)) + 0.5))[2:].zfill(L)
  x binary parent2 = bin(int((parent2[0] * (2 ** L - 1)) + 0.5))[2:].zfill(L)
  y binary parent1 = bin(int(((parent1[1] + 2) / 4) * (2 ** L - 1) + 0.5))[2:].zfill(L)
  y binary parent2 = bin(int(((parent2[1] + 2) / 4) * (2 ** L - 1) + 0.5))[2:].zfill(L)
  x child = int(x binary parent1[:point1] + x binary parent2[point1:point2] +
x binary parent1[point2:], 2) / (2 ** L - 1)
  y child = -2 + int(y binary parent1[:point1] + y binary parent2[point1:point2] +
y binary parent1[point2:], 2) / (2 ** L - 1) * 4
```

```
return x child, y child
def mutation(child, mutation rate):
  x binary = bin(int((child[0] * (2 ** L - 1)) + 0.5))[2:].zfill(L)
  y binary = bin(int(((child[1] + 2) / 4) * (2 ** L - 1) + 0.5))[2:].zfill(L)
  if np.random.rand() < mutation rate:
     mutated bit x = np.random.randint(L)
     x binary = x binary[:mutated bit x] + ('0' if x binary[mutated bit x] == '1'
else '1') + x binary
                                                             mutated bit x + 1:
  if np.random.rand() < mutation rate:
     mutated bit y = np.random.randint(L)
     y binary = y binary[:mutated bit y] + ('0' if y binary[mutated bit y] == '1'
else '1') + y_binary[
                                                             mutated bit y + 1:
  child = (int(x_binary, 2) / (2 ** L - 1), -2 + int(y binary, 2) / (2 ** L - 1) * 4)
  return child
def plot 3d surface():
  fig = plt.figure()
  ax = fig.add subplot(111, projection='3d')
  x vals = np.linspace(0, 2, 100)
  y vals = np.linspace(-2, 2, 100)
  X, Y = np.meshgrid(x vals, y vals)
  Z = fitness function(X, Y)
  ax.plot surface(X, Y, Z, cmap='viridis', alpha=0.8)
  ax.set xlabel('X')
  ax.set ylabel('Y')
  ax.set zlabel('Fitness')
  plt.savefig('3D.png')
def plot average fitness(generation values, average fitness values):
  plt.figure()
  plt.plot(generation values[:len(average fitness values)], average fitness values,
```

marker='o',

label='Average Fitness')

plt.title('Average Fitness for Generations')

```
plt.xlabel('Generation')
  plt.ylabel('Average Fitness')
  plt.grid(True)
  plt.legend()
  plt.savefig('average - fitness.png')
def plot population values(generation, x values, y values):
  plt.figure()
  plt.scatter(x values, y values, marker='o', label='Population Values')
  additional points x = [0, 2]
  additional points y = [-2, 2]
  plt.scatter(additional points x, additional points y, color='red', marker='o',
label='Critical Points')
  plt.title(f'Population Values for Generation {generation}')
  plt.xlabel('X values')
  plt.ylabel('Y values')
  plt.legend()
  plt.grid(True)
  plt.savefig(f'population - values - {generation}.png')
def genetic algorithm(population size, generations, populations to display):
  population = initialize population(population size)
  best overall fitness = -np.inf
  best overall individual = None
  average fitness values = []
  for generation in range(generations):
     fitness values = [fitness function(x, y) for x, y in population]
     if generation in populations to display:
       print(f"\nX values for Population {generation}:")
       for i in range(min(10, population size)):
          print(round(population[i][0], 4))
       print(f"\nY values for Population {generation}:")
       for i in range(min(10, population size)):
          print(round(population[i][1], 4))
       print(f"\nFitness values for Population {generation}:")
       for i in range(min(10, population size)):
          print(round(fitness values[i], 4))
       average fitness = np.mean(fitness values)
```

```
print(f"\nAverage Fitness for Population {generation}:
{round(average fitness, 4)}")
       print(f"Max Fitness for Population {generation}: {round(max(fitness values),
4)}")
       average fitness values.append(average fitness)
       x values = [individual[0] for individual in population[:10]]
       y values = [individual[1] for individual in population[:10]]
       plot population values(generation, x values, y values)
     if max(fitness values) > best overall fitness:
       best overall fitness = max(fitness values)
       best overall individual = population[np.argmax(fitness values)]
     parents = [roulette selection(population, fitness values) for in
range(population size)]
     children = []
     for i in range(0, population size, 2):
       parent1 = parents[i]
       parent2 = parents[i + 1]
       child1 = two point crossover(parent1, parent2)
       child2 = two point crossover(parent2, parent1)
       children.extend([mutation(child1, 0.25), mutation(child2, 0.25)])
     population = children
  print(
     f"\nOverall Best Solution: ({round(best overall individual[0], 4)},
{round(best_overall_individual[1], 4)}), Overall Best Fitness:
{round(best overall fitness, 4)}")
  plot average fitness(range(generations), average fitness values)
  plot 3d surface()
genetic algorithm(population size=4, generations=100, populations to display=[0,
1, 2, 3, 4, 5, 6, 7, 8, 9, 10])
```

# Приложение Б

